

Peipers-RNAseq docente para tomate

Desde ENA/SRA hasta TPM-consultor | BioProject PRJNA1347747

AUTOR Y CREADOR

Samuel Parra A., PhD

Filiación actual

Centro de Biotecnología Molecular Vegetal, Departamento de Ciencias, Universidad de Chile.

Investigador postdoctoral en el laboratorio de la Dra. Claudia Stange.

Correo institucional: sa.parra@uandresbello.edu

ORCID: <https://orcid.org/0000-0002-9129-4133>

COPYRIGHT Y LICENCIA

Copyright (c) 2026 Samuel Parra A., PhD.

Peipers-RNAseq y su documentación se distribuyen bajo licencia MIT. Las copias y trabajos derivados deben conservar el aviso de copyright y el texto de la licencia incluidos en el paquete.

Peipers-RNAseq docente para tomate

Guía docente y operativa

Fuente versionada: README.md

Pipeline docente Peipers-RNAseq para tomate | Edición 10 agosto 2026

Esta carpeta permite que un alumno con poca experiencia procese datos RNA-seq de tomate desde ENA/SRA hasta un consultor TPM, aprenda qué hace cada etapa y entregue un resultado incorporable a [TPM-consultor](#).

El caso preparado es [PRJNA1347747](#), asociado al trabajo Low ethylene production in the root(stock) alleviates salt stress in tomato. También se incluye una herramienta para iniciar otros BioProjects.

Productos finales

- 18 cuantificaciones Salmon, una por corrida SRR.
- Matrices de TPM y lecturas estimadas a nivel de transcrito y gen.
- Un informe MultiQC.
- Un paquete verificable apto para un pull request.
- Un consultor standalone con su propio SQLite.
- Opcionalmente, contrastes de expresión diferencial con DESeq2.

Los FASTQ ocupan aproximadamente 92,5 GiB y quedan fuera de GitHub.

Conceptos que debe aprender el alumno

- **BioProject**: agrupación pública de muestras y archivos de un estudio.
- **SRR**: identificador de una corrida de secuenciación.
- **FASTQ**: secuencias leídas por el equipo y calidad de cada base.
- **Referencia transcriptómica**: transcritos conocidos contra los que se cuantifican las lecturas.
- **Salmon**: estima cuántas lecturas proceden de cada transcrito.
- **TPM**: abundancia normalizada dentro de una biblioteca. Sirve para explorar perfiles; no reemplaza conteos ni DESeq2.
- **MD5/SHA-256**: huellas digitales para detectar archivos incompletos o diferentes.
- **FastQC/MultiQC**: diagnóstico de calidad; no cambian las lecturas.
- **DESeq2**: modelo estadístico de conteos para condiciones con réplicas.

Diseño experimental curado

Todas las bibliotecas son RNA-seq paired-end de hoja, 100 nt, BGISEQ-500.

Vástago/portainjerto	Tratamiento	Réplicas SRR
UD/WT	Control	SRR35859425, SRR35859424, SRR35859415
UD/WT	75 mM NaCl	SRR35859408, SRR35859423, SRR35859422
UD/epi	Control	SRR35859414, SRR35859413, SRR35859412

Vástago/portainjerto	Tratamiento	Réplicas SRR
UD/epi	75 mM NaCl	SRR35859421, SRR35859420, SRR35859419
UD/ACCD	Control	SRR35859411, SRR35859410, SRR35859409
UD/ACCD	75 mM NaCl	SRR35859418, SRR35859417, SRR35859416

El manifiesto completo incluye BioSample, experimento, URL, MD5 y tamaño: **manifests/PRJNA1347747_runs.tsv**.

Por qué estos TPM son compatibles

El artículo original usó STAR y featureCounts. Para comparar con los TPM históricos del consultor, esta ruta vuelve a cuantificar con:

- ITAG4.0_cDNA.fasta e ITAG4.0_gene_models.gff;
- Salmon 2.0.1;
- índice k=31;
- detección de orientación -l A;
- lecturas paired-end comprimidas de ENA;
- sin seqBias, gcBias ni recorte por defecto.

Las referencias se descargan del [release oficial ITAG4.0 de SGN](#) y se exigen estas huellas:

```
ITAG4.0_cDNA.fasta 2956f6f4c76c09eae65d8732d9fa02d3682a0bff35a3b5027473d224f7beb32
ITAG4.0_gene_models.gff 61bdf7c0a607c723fa75c3b3139690489aedf23c0dcc230e15050b6edfc9f820
```

Comparable técnicamente no significa libre de efectos de lote. Cultivar, edad, tejido, plataforma y laboratorio aún influyen. No use DESeq2 mezclando BioProjects no balanceados.

Flujo

ENTRADAS	CONTROL Y REFERENCIA	CUANTIFICACION	PRODUCTOS
ENA: FASTQ pareados ITAG4.0	MD5 + FastQC/MultiQC Índice Salmon 2.0.1	Salmon quant quant.sf	Matrices Bundle PR Consultor DESeq2

1. Preparar Windows y Ubuntu/WSL2

1.1 Revisar recursos

En Administrador de tareas > Rendimiento anote procesadores lógicos, RAM y espacio libre.

- 8 procesadores lógicos o más.
- 32 GB RAM ideal; con 16 GB use 4 hilos.
- 130 GB libres como mínimo; 150-200 GB dan margen.

No use OneDrive para los datos grandes.

1.2 Instalar WSL2

Abra PowerShell como administrador:

```
wsl --install -d Ubuntu-24.04
```

Reinicie si se solicita. Abra Ubuntu, cree usuario y contraseña. Al escribir la contraseña no se muestran caracteres; es normal.

```
sudo apt update
sudo apt install -y git wget bzip2 ca-certificates
nproc
free -h
df -h
```

1.3 Instalar Miniforge

Conda crea ambientes aislados y evita mezclar versiones.

```
cd ~
wget -O Miniforge3.sh https://github.com/conda-forge/miniforge/releases/latest/download/Miniforge3-Linux-x86_64.sh
bash Miniforge3.sh
```

Acepte la licencia, use la ruta sugerida y permita inicializar el shell. Cierre y vuelva a abrir Ubuntu:

```
conda --version
```

2. Crear fork y rama

1. Abra TPM-consultor en GitHub.
2. Pulse **Fork**.
3. Reemplace USUARIO GITHUB:

```
cd ~
git clone https://github.com/USUARIO_GITHUB/TPM-consultor.git
cd TPM-consultor
git switch -c dataset/prjna1347747
git config --global user.name "Nombre Apellido"
git config --global user.email "correo-asociado-a-github"
```

Clone dentro de la carpeta Linux, no en /mnt/c/.../OneDrive.

3. Crear el ambiente

```
cd ~/TPM-consultor
conda config --set channel_priority strict
conda env create -f peipers_rnaseq/environment.yml
conda activate peipers-rnaseq-tomate
python --version
salmon --version
fastqc --version
multiqc --version
```

Salmon debe informar 2.0.1. No actualice programas durante el análisis.

4. Configurar sin cambiar archivos versionados

```
cp peipers_rnaseq/config/PRJNA1347747.env peipers_rnaseq/config/local.env
nano peipers_rnaseq/config/local.env
```

Use THREADS=4 con 16 GB RAM y THREADS=8 con 32 GB o más. Cambie WORK_DIR si otro disco tiene más espacio. Ejemplo:

```
WORK_DIR="/mnt/d/rnaseq-work/PRJNA1347747"
```

El disco de Windows puede ser más lento, pero es preferible a llenar C:. No use una ruta de OneDrive.

```
cd ~/TPM-consultor/peipers_rnaseq
bash run_pipeline.sh preflight config/local.env
```

El preflight se detiene si falta software, la metadata es inconsistente, Salmon no es 2.0.1 o falta espacio.

5. Referencia e índice

```
bash run_pipeline.sh reference config/local.env
```

La etapa descarga cDNA/GFF, verifica SHA-256, construye el índice y comprueba versión, k y 33.976 transcritos. Es reanudable.

6. Descargar FASTQ

```
bash run_pipeline.sh download config/local.env
```

Hay 36 archivos. La descarga se reanuda si se corta Internet. Cada archivo se acepta sólo si tamaño y MD5 coinciden con ENA. Si Windows reinicia, ejecute el mismo comando.

No edite ni copie FASTQ al repositorio.

7. Control de calidad

```
bash run_pipeline.sh qc config/local.env
```

Abra `WORK_DIR/qc/multiqc/multiqc_report.html`. Revise:

- que estén todos los SRR;
- calidad por posición;
- adaptadores intensos;
- contenido GC anómalo;
- una biblioteca claramente distinta en calidad o profundidad.

No se recorta automáticamente para conservar comparabilidad. Si el QC muestra un problema grave, detenga el análisis y consulte al supervisor.

8. Cuantificar

```
bash run_pipeline.sh quant config/local.env
```

El comando conceptual es:

```
salmon quant -i INDICE -l A -1 MATE_1.fastq.gz -2 MATE_2.fastq.gz -p HILOS -o SALIDA
```

Cada resultado debe tener 33.976 transcritos, suma TPM cercana a un millón, Salmon 2.0.1 y al menos 40 % de mapeo. Una salida incompleta nunca se sobrescribe silenciosamente.

9. Construir matrices

```
bash run_pipeline.sh matrices config/local.env
```

Se generan:

- Transcript_TPM.tsv y Transcript_NumReads.tsv.
- Gene_TPM.tsv y Gene_NumReads.tsv.
- tx2gene.tsv.
- salmon_qc.tsv.

Los TPM de gen son sumas de sus transcritos según ITAG4.0. tx2gene registra la agregación y permite usar tximport.

10. Consultor standalone

```
bash run_pipeline.sh consultor config/local.env
source config/local.env
cd "$WORK_DIR/consultor_standalone/PRJNA1347747"
python app.py
```

Abra <http://127.0.0.1:8765>. Pruebe:

```
Solyc07g049530
Solyc12g005940
Solyc02g084850
```

Debe mostrar seis condiciones con tres réplicas.

11. Paquete y pull request

```
cd ~/TPM-consultor/peipers_rnaseq
bash run_pipeline.sh bundle config/local.env
bash run_pipeline.sh verify config/local.env
source config/local.env
cd ~/TPM-consultor
mkdir -p datasets
cp -a "$WORK_DIR/bundle/PRJNA1347747" datasets/
python peipers_rnaseq/scripts/verify_bundle.py --bundle datasets/PRJNA1347747
git status --short
```

El paquete incluye metadata, quant.sf, matrices, QC y checksums. Excluye FASTQ, SRA, referencia, índice y SQLite.

Sólo debe aparecer datasets/PRJNA1347747. Si aparecen datos grandes, deténgase.

```
git add datasets/PRJNA1347747
git diff --cached --stat
git commit -m "Agregar PRJNA1347747 procesado con Peipers-RNAseq"
git push -u origin dataset/prjna1347747
```

En GitHub pulse **Compare & pull request**. Incluya BioProject, diseño, ITAG4.0, Salmon 2.0.1, confirmación MD5, rango de mapeo, MultiQC y resultado del verificador. No haga push directo a main.

12. DESeq2 opcional

DESeq2 no analiza TPM; importa las estimaciones Salmon con tximport.

```
cd ~/TPM-consultor
conda env create -f peipers_rnaseq/optional_deseq2/environment-deseq2.yml
conda activate peipers-rnaseq-deseq2
cd peipers_rnaseq
bash run_pipeline.sh deseq2 config/local.env
```

El diseño es genotype, treatment y su interacción. Produce sal vs control dentro de WT/epi/ACCD, comparaciones de portainjertos, interacciones, conteos normalizados, PCA, distancias y sessionInfo.txt.

Interprete $p_{adj} < 0.05$ junto con $\log_2\text{FoldChange}$. Una interacción significativa indica que la respuesta a sal difiere respecto de WT. Use estos contrastes sólo dentro de PRJNA1347747.

13. Otro BioProject de tomate

```
conda activate peipers-rnaseq-tomate
python scripts/fetch_ena_manifest.py \
  --project PRJNA_OTRO \
  --output manifests/PRJNA_OTRO_runs.draft.tsv
```

Después:

1. Lea el artículo y los BioSamples.
2. Reemplace todos los campos REVISAR.
3. Cree PRJNA_OTRO_samples.tsv.
4. Copie la configuración y cambie proyecto, nombres y WORK_DIR.
5. Ejecute validate_project.py.
6. Procese con la misma referencia y Salmon.

Este camino integra datasets de tomate cuantificables contra ITAG4.0. Otra especie requiere otra referencia y un consultor separado.

Problemas frecuentes

Espacio insuficiente

Cambie WORK_DIR. No reduzca MIN_FREE_GB para ignorar el problema.

MD5 incorrecto

No use el archivo. Conserve el mensaje y mueva el .part sospechoso a otra carpeta antes de reintentar.

Salmon no es 2.0.1

```
conda activate peipers-rnaseq-tomate
conda list salmon
```

Si el ambiente fue modificado, créelo desde environment.yml.

Windows reinició

Active el ambiente y repita la etapa. El pipeline reutiliza resultados válidos.

Mapeo bajo 40 %

No cambie el umbral. Revise especie, pares, FastQC y logs con el supervisor.

Liberar espacio

Primero valide:

```
bash run_pipeline.sh verify config/local.env
source config/local.env
du -sh "$WORK_DIR/fastq" "$WORK_DIR/quant" "$WORK_DIR/bundle"
readlink -f "$WORK_DIR/fastq"
```

Sólo si la ruta resuelta es exactamente la carpeta FASTQ del proyecto:

```
rm -r -- "$WORK_DIR/fastq"
```

Esto libera cerca de 100 GB y no se puede deshacer localmente. Conserve quant, matrices, bundle y consultor.

Lista de éxito

- ☐ Trabajé en una rama de mi fork.
- ☐ Preflight terminó sin errores.
- ☐ Las referencias pasaron SHA-256.
- ☐ Los 36 FASTQ pasaron MD5 y tamaño.
- ☐ Revisé MultiQC.
- ☐ Las 18 cuantificaciones pasaron validación.
- ☐ El consultor muestra seis condiciones con tres réplicas.
- ☐ verify_bundle.py terminó con OK.
- ☐ Git no muestra FASTQ, SRA, índices ni SQLite.
- ☐ Abrí un pull request.

La incorporación al consultor unificado está en [GUIA_MANTENEDOR.md](#).